

Disciplina de Inteligência Artificial

Professor Munif Gebara Junior — Unicesumar 2026

Trabalho Final

Classificação de Tumores de Mama com KNN e Redes Neurais Artificiais

Integrante	RA
Vinícius César Chaves Nunes	23000808-2

1. Resumo do Projeto

O câncer de mama é uma das doenças mais prevalentes no mundo, e o diagnóstico precoce é fator determinante para o sucesso do tratamento. Este trabalho aplica técnicas de Inteligência Artificial para classificar tumores como malignos ou benignos com base em características clínicas extraídas de exames de biópsia. Foram utilizados dois modelos: **KNN (K-Nearest Neighbors)**, método da Parte 1 da disciplina, e **RNA (Rede Neural Artificial — MLP)**, método da Parte 2. Os modelos foram treinados, avaliados com métricas e gráficos, e comparados entre si.

Hipótese: ambos os modelos conseguem classificar tumores com alta acurácia, mas esperamos que a RNA apresente desempenho superior ao KNN por conseguir capturar relações não-lineares nos dados.

2. Dataset

Foi utilizado o **Breast Cancer Wisconsin Dataset**, disponível na biblioteca scikit-learn. Trata-se de um dataset público e amplamente utilizado em benchmarks de aprendizado de máquina.

Atributo	Valor
Origem	UCI Machine Learning Repository / scikit-learn
Total de amostras	569 registros
Número de features	30 atributos numéricos
Variável alvo	Classe do tumor: 0 = Maligno, 1 = Benigno
Divisão treino/teste	426 treino / 143 teste (75% / 25%)
Pré-processamento	Padronização com StandardScaler (média=0, desvio=1)

Os atributos descrevem características dos núcleos celulares presentes nas biópsias, como raio, textura, perímetro, área, suavidade, compacidade, concavidade, simetria e dimensão fractal. Cada

atributo é fornecido em três versões: média, erro padrão e pior valor, totalizando 30 features.

3. Métodos de Inteligência Artificial

3.1 KNN — K-Nearest Neighbors (Parte 1)

O KNN é um algoritmo de aprendizado supervisionado baseado em distância. Para classificar um novo exemplo, ele calcula a distância (Euclidiana, por padrão) até os K vizinhos mais próximos no conjunto de treino e atribui a classe majoritária entre eles.

- Parâmetro utilizado: **K = 5** vizinhos
- Métrica de distância: **Euclidiana**
- Dados normalizados com StandardScaler antes do treinamento

3.2 RNA — Rede Neural Artificial / MLP (Parte 2)

A Rede Neural Artificial (MLP — Multilayer Perceptron) é um modelo inspirado no funcionamento do cérebro humano, composto por camadas de neurônios artificiais que aprendem padrões complexos nos dados por meio de retropropagação (backpropagation).

- Arquitetura: **2 camadas ocultas (64 e 32 neurônios)**
- Função de ativação: **ReLU**
- Máximo de iterações: **300 épocas** (com early stopping)
- Convergiu em: **21 épocas**
- Dados normalizados com StandardScaler antes do treinamento

4. Avaliação dos Modelos

4.1 Métricas de Desempenho

Métrica	KNN (K=5)	RNA (MLP)	Melhor Modelo
Acurácia	0.9790	0.9371	KNN ✓
Precisão	0.9677	0.9451	KNN ✓
Recall	1.0000	0.9556	KNN ✓
F1-Score	0.9836	0.9503	KNN ✓

4.2 Gráfico — Comparação de Métricas




Figura 1 — Comparação das métricas de avaliação entre KNN e RNA.

4.3 Matrizes de Confusão




Figura 2 — Matrizes de confusão de ambos os modelos no conjunto de teste.

4.4 Curva de Perda — RNA




Figura 3 — Evolução da perda (loss) durante o treinamento da Rede Neural.

4.5 KNN — Variação do Parâmetro K




Figura 4 — Acurácia do KNN para diferentes valores de K (1 a 20). K=5 foi escolhido.

5. Comparação dos Resultados e Conclusão

Contrariando a hipótese inicial, o **KNN com K=5 obteve desempenho superior à RNA** em todas as métricas avaliadas. O KNN alcançou acurácia de **97.9%** e F1-Score de **0.9836**, enquanto a RNA obteve acurácia de **93.7%** e F1-Score de **0.9503**.

Um ponto de destaque é o **Recall perfeito do KNN (1.0000)**, o que significa que o modelo não deixou escapar nenhum tumor maligno — erro crítico em diagnósticos médicos. Para o problema de classificação de tumores, o Recall é a métrica mais importante, pois um falso negativo (classificar um tumor maligno como benigno) é muito mais grave que um falso positivo.

A RNA, apesar de não superar o KNN neste dataset, demonstrou convergência estável e apresenta maior potencial de escalabilidade para datasets maiores e mais complexos. Para o dataset Breast Cancer Wisconsin — com apenas 569 amostras — o KNN mostrou ser suficiente e mais eficiente.

Pontos-chave da comparação:

Critério	Análise
Acurácia	KNN 97.9% > RNA 93.7% → KNN melhor
Recall	KNN 100% vs RNA 95.6% → KNN muito superior para diagnóstico
Complexidade	KNN é mais simples; RNA é mais flexível para problemas maiores
Tempo de treino	KNN treina instantaneamente; RNA requer iterações de backpropagation
Conclusão geral	Para este dataset, o KNN foi o modelo mais adequado

6. Como Executar o Projeto

Instalação das dependências:

```
pip install scikit-learn matplotlib pandas numpy
```

Treinamento dos modelos (main.py):

```
from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.neural_network import MLPClassifier
from sklearn.metrics import accuracy_score, f1_score

data = load_breast_cancer()
X_train, X_test, y_train, y_test = train_test_split(
    data.data, data.target, test_size=0.25, random_state=42,
    stratify=data.target)

scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

# KNN - Parte 1
knn = KNeighborsClassifier(n_neighbors=5)
knn.fit(X_train, y_train)

# RNA - Parte 2
rna = MLPClassifier(hidden_layer_sizes=(64, 32), max_iter=300, random_state=42)
rna.fit(X_train, y_train)

print("KNN Acurácia:", accuracy_score(y_test, knn.predict(X_test)))
print("RNA Acurácia:", accuracy_score(y_test, rna.predict(X_test)))
```

Estrutura do repositório GitHub:

```
trabalho-final-ia/
■■■ main.py ← código principal (treino + avaliação)
■■■ graficos/ ← gráficos gerados
■■■ README.md ← documentação completa
■■■ relatorio.pdf ← este documento
■■■ requirements.txt ← dependências
```